UNIVERSIDAD AUTONOMA

BENJAMIN FUENTES
MARTIN INOSTROZA
FERNANDA GARCIA

CO2
EN EL TIEMPO

CO2 EN EL TIEMPO

DIAGNOSTICO DE CALIDAD DE DATOS

PROYECTO: EVOLUCIÓN DE EMISIONES DE CO2 POR PAIS
FUENTE: OUR WORLD IN DATA
REGISTROS INICIALES: 50.411
VARIABLES INCIALES: 79

Python | Diagnóstico inicial de calidad de datos

```
>>> import pandas as pd
>>> df = pd.read_csv("owid-co2-data.csv")
>>> VARIABLES = ["country", "year", "iso_code", "population", "gdp", "co2",
...              "co2_per_capita", "co2_growth_prct",
...              "share_global_co2", "cumulative_co2"]
>>> df[VARIABLES].isna().sum()

gdp                 35160
co2_growth_prct     24172
co2_per_capita      23902
share_global_co2    22848
cumulative_co2      22848
co2                 21027
population           9244
iso_code             7931
year                    0
country                 0
dtype: int64

>>> df.shape
(50411, 79)
>>> df.duplicated().sum()
0
```

PROBLEMA DETECTADO	CANTIDAD
Valores nulos	2.105.184
Filas duplicadas	0
Entidades sin código ISO	36
Valores sobre 100t per capita	36

PRINCIPAL PROBLEMA ENCONTRADO

El principal problema fue la mezcla de países con agregados geográficos, como World y continentes, que representaban el 15,7 % de las filas. Esto podía distorsionar las comparaciones de emisiones. Además, los valores nulos se concentraban principalmente antes de 1950.



TRATAMIENTO DE VALORES NULOS

VARIABLE	NULOS INICIALES	ESTRATEGIA
CO2	21.027	Interpolación
CO2 per capita	23.902	Recalcular
Poblacion	9.244	Mantener
PIB	35.160	Mantener
Variacion Anual	24.172	Mantener
Participación Mundial	22.848	Recalcular
CO2 Acomulado	22.848	Interpolación

Solo se completaron 8 valores mediante interpolación o recálculo. Los demás nulos se mantuvieron cuando representaban ausencia real de información o datos no disponibles.

TRANSFORMACIONES

REALIZADAS

CONVERSIÓN DE FECHAS

```
df["fecha"] = pd.to_datetime(
    df["anio"].astype(str), format="%Y"
)
```

CLASIFICACION DE PERIODOS

```
df["periodo_politica"] = pd.cut(
    df["anio"],
    bins=[-float("inf"), 1996, 2014, float("inf")],
    labels=["pre_kioto", "kioto_a_paris", "post_paris"]
)
```

CREACION DE DECADAS

```
df["decada"] = (df["anio"] // 10) * 10
```

CONVERSION. DE UNIDADES

```
df["co2_gt"] = df["co2_mt"] / 1000
```

Estas decisiones permiten trabajar con información más confiable, evitar comparaciones duplicadas, organizar las emisiones por períodos y conservar los datos faltantes cuando no existe información suficiente para reemplazarlos.

DATA SET
LIMPIO Y ORGANIZADO

COMPARACIÓN

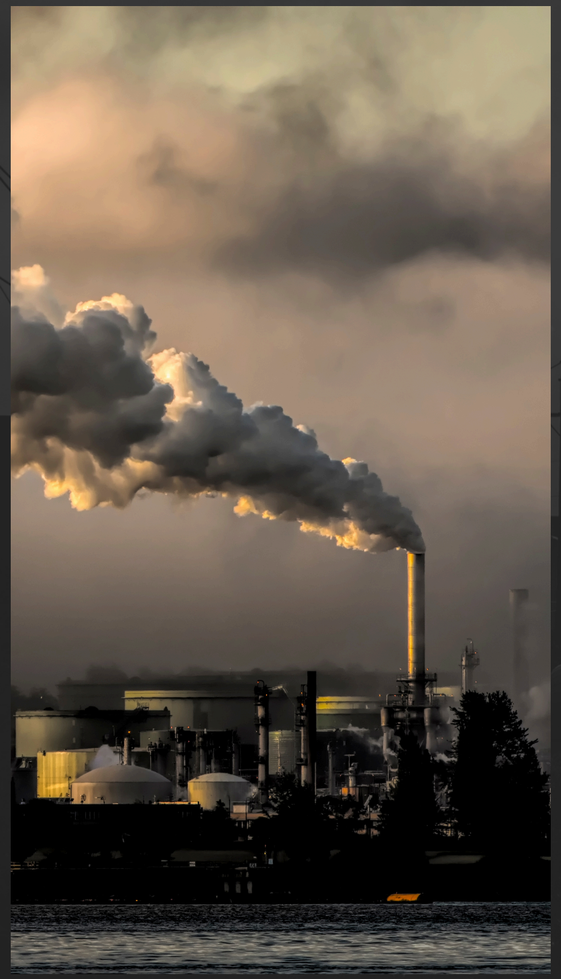
Indicador	Antes	Después
Registros	50.411	16.200
Variables	79	17
Nulos (10 variables clave)	167.132	9.632
Duplicados	0	0



EVIDENCIA FINAL DEL DATASET FINAL

País	Año	Período	CO_2
Rwanda	2006	kioto_a_paris	0.514
Georgia	1978	pre_kioto	12.339
Panama	1967	pre_kioto	2.150
Montserrat	2004	kioto_a_paris	0.048
Uganda	1955	pre_kioto	0.264

APRENDIZAJES OBTENIDOS



16.200	17	9.632
Registros finales	Variables finales	Nulos en 10 variables clave

216 países · Período 1950–2024

34 valores atípicos identificados en el dataset final y marcados, sin eliminarlos.

¿QUÉ FUE LO MÁS DIFÍCIL DEL PROCESO?

Distinguir entre valores nulos que representan errores y aquellos que significan ausencia de información.

¿QUÉ DECISIÓN TUVO MAYOR IMPACTO?

Separar los países de los agregados geográficos y delimitar el análisis entre 1950 y 2024.

¿QUÉ HARÍAMOS DISTINTO EN UNA PRÓXIMA ITERACIÓN?

Elaborar desde el inicio un registro de hitos y períodos de política climática.