PROGRAMACIÓN AVANZADA
ING. CIVIL PLAN COMUN– SEDE TEMUCO

"EVOLUCIÓN DE EMISIONES DE CO_2"

Universidad Autónoma de Chile
Avance 2: limpieza, tratamiento de nulos y transformación de datos
Sección: 1 y 2 Docente: Alex
Repositorio: fernandagarcia111/emisiones-co2-pipeline: Pipeline en Python y Pandas para analizar la evolución de emisiones de CO2 (Programación Avanzada, Grupo 6)

Nº Grupo	:	6
Integrantes	:	Fernanda García
		Benjamín Fuentes
		Martin Inostrosa
		Martin García
Fecha	:	03/11/2026
Nota	:	

INFORME N°2

Características generales

Este informe corresponde al Avance 2 del Proyecto Final Integrador y amplía el Avance 1. En la primera semana el trabajo consistió en definir el problema y cargar el archivo. En esta etapa el equipo preparó los datos para el análisis: diagnosticó su calidad, aplicó limpieza y tratamiento de nulos, creó variables nuevas y organizó todo el proceso en módulos que se ejecutan con un solo comando. El archivo original no se modificó; el resultado se guarda aparte en datos/procesados/dataset_limpio.csv.

Elemento	Detalle
Actividad	Avance 2 del Proyecto Final Integrador
Grupo y proyecto	Grupo 6, Proyecto 6: Evolución de Emisiones de CO_2
Lenguaje y biblioteca	Python 3 y Pandas
Dataset original	datos/originales/owid-co2-data.csv (sin modificaciones)
Dataset procesado	datos/procesados/dataset_limpio.csv
Repositorio	fernandagarcia111/emisiones-co2-pipeline: Pipeline en Python y Pandas para analizar la evolución de emisiones de CO2 (Programación Avanzada, Grupo 6)
Archivo del informe	reportes/avance_2.pdf

Resumen del Avance 1

El proyecto busca responder si las políticas ambientales han influido en la reducción de las emisiones de CO_2, con un ranking de emisiones, su evolución temporal y una proyección anual como productos esperados. Se trabaja con el conjunto de datos de Our World in Data (50.411 registros, 79 variables, años 1750 a 2024, licencia CC BY 4.0), consultado el 27/10/2026. El problema, la fuente y el diccionario de datos original están en reportes/avance_1.pdf.

En este segundo avance, el trabajo se concentra en preparar y validar los datos necesarios para desarrollar posteriormente el ranking de emisiones, el análisis de evolución temporal y la proyección anual. La evaluación de la influencia de las políticas ambientales requerirá complementar el dataset con información específica sobre los acuerdos y medidas implementadas por cada país.

Diagnóstico de calidad

El diagnóstico se ejecuta con diagnosticar() (src/validaciones.py) sobre el archivo tal como se descargó, antes de tocar cualquier dato. La Tabla 1 resume los indicadores.

Indicador	Resultado en el archivo original
Filas y columnas	50.411 filas y 79 columnas
Tipos de datos	76 float64, 1 int64 y 2 de texto

Indicador	Resultado en el archivo original
Valores nulos	2.105.184 (52,9 % de las celdas)
Filas duplicadas	0 (y 0 pares country y year repetidos)
Valores fuera de rango	36, todos en co2_per_capita (más de 100 t por persona)
Categorías inconsistentes	36 entidades sin código ISO: 35 agregados o regiones y Kosovo, que sí es un país
Espacios sobrantes en texto	0
Ceros en co2	1.354 registros en 50 entidades

Tabla 1. Diagnóstico del dataset original.

El campo codigo_iso presenta 7.931 registros sin código ISO, equivalentes al 15,7 % de las filas del archivo original. Sin embargo, estos registros no corresponden exclusivamente a agregados geográficos. De ellos, 7.757 pertenecen a 35 entidades agregadas o regiones, como World, continentes y grupos de ingreso. Los 174 registros restantes corresponden a Kosovo, que sí es un país, pero no cuenta con un código ISO oficial en la fuente. Por esta razón, los agregados se separaron del conjunto de países y Kosovo fue identificado mediante el código de uso común XKX.

Los rangos usados para detectar valores fuera de rango son: year entre 1750 y 2024; population y gdp mayores que 0; co2 y cumulative_co2 mayores o iguales que 0; share_global_co2 entre 0 y 100; y co2_per_capita entre 0 y 100 t por persona. Este último límite es de plausibilidad: ningún país mantiene valores sobre esa cifra de forma sostenida.

Variable	Nulos	% del total
gdp	35.160	69,7
co2_growth_prct	24.172	47,9
co2_per_capita	23.902	47,4
share_global_co2	22.848	45,3
cumulative_co2	22.848	45,3
co2	21.027	41,7
population	9.244	18,3
iso_code	7.931	15,7
year	0	0,0
country	0	0,0

Tabla 2. Valores nulos en las variables del diccionario.

```
Valores nulos en las variables del diccionario:
                  nulos  porcentaje
gdp               35160        69.7
co2_growth_prct   24172        47.9
co2_per_capita    23902        47.4
share_global_co2  22848        45.3
cumulative_co2    22848        45.3
co2               21027        41.7
population         9244        18.3
iso_code           7931        15.7
year                  0         0.0
country               0         0.0
```

```
df[variables].info():
<class 'pandas.DataFrame'>
RangeIndex: 50411 entries, 0 to 50410
Data columns (total 10 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   country           50411 non-null  str
 1   year              50411 non-null  int64
 2   iso_code          42480 non-null  str
 3   population        41167 non-null  float64
 4   gdp               15251 non-null  float64
 5   co2               29384 non-null  float64
 6   co2_per_capita    26509 non-null  float64
 7   co2_growth_prct   26239 non-null  float64
 8   share_global_co2  27563 non-null  float64
 9   cumulative_co2    27563 non-null  float64
dtypes: float64(7), int64(1), str(2)
memory usage: 3.8 MB
```

Figura 1. Salida real del diagnóstico: nulos por variable e información del DataFrame original.

Interpretación

El principal problema de calidad del conjunto de datos no se encuentra en los tipos de datos ni en los registros duplicados, sino en la mezcla de entidades agregadas con países y en la cobertura desigual de información a lo largo del tiempo. El 15,7 % de las filas presenta el campo codigo_iso vacío; sin embargo, estos registros incluyen tanto agregados geográficos como los correspondientes a Kosovo, por lo que fue necesario diferenciarlos antes de realizar la limpieza.

Además, gran parte de los valores nulos de las variables co2 y co2_per_capita corresponde a años anteriores a 1950, período en el que existe una cobertura limitada de información para numerosos países. También se detectaron 36 valores superiores a 100 toneladas de CO_2 por persona, asociados a cinco territorios pequeños: Sint Maarten, Curazao, Qatar, Brunéi y Kuwait. Estos valores requieren una revisión especial, ya que una población reducida puede producir cifras per cápita elevadas.

Limpieza realizada

Ninguna corrección se hizo sobre el archivo original. Cada función de src/limpieza.py trabaja sobre una copia en memoria y deja constancia de lo que elimina o cambia en una lista que main.py exporta a reportes/registro_limpieza.csv. La Tabla 3 reúne las decisiones.

Problema	Acción aplicada	Filas afectadas	Justificación
Nombres de columnas en inglés	Normalizar y renombrar al español	10 columnas	Facilita el uso del dataset y su documentación.
Espacios sobrantes en texto	Eliminar espacios al inicio, al final y duplicados	0	No hubo casos; la regla queda para futuras versiones.
Agregados y regiones mezclados con países	Eliminar 35 entidades sin código ISO	7.757	Duplican las emisiones de los países. World se guarda aparte en serie_mundial.csv.
Kosovo sin código ISO	Asignar el código XKX	174	Es un país. XKX es de uso común, aunque no es oficial ISO.
Registros anteriores a 1950	Eliminar	26.229	Cobertura escasa y concentración de nulos. Kioto y París quedan dentro del período.

Problema	Acción aplicada	Filas afectadas	Justificación
Países sin ningún dato de CO_2	Eliminar Monaco, San Marino y Vaticano	225	No aportan información sobre la variable principal.
Filas duplicadas	Eliminar (no se encontraron)	0	Registro idéntico a otro.
Identificadores repetidos	Revisar pares pais y anio	0	Cada par debe ser único.
Columnas fuera del diccionario	Descartar 69 columnas	69 columnas	Desagregaciones por combustible, otros gases y temperatura; 9 tienen más de 90 % de nulos.
Valores sobre 100 t per cápita	Mantener y marcar en atipico_per_capita	34 en el período	Son valores reales de territorios pequeños, no errores de la fuente.

Tabla 3. Registro de decisiones de limpieza.

En total se eliminaron 34.211 registros del conjunto original. Esta cantidad corresponde a 7.757 registros de entidades agregadas o regiones, 26.229 registros anteriores a 1950 y 225 registros pertenecientes a Mónaco, San Marino y Vaticano, que no presentaban información de CO_2. Después de aplicar estos criterios de limpieza, el conjunto quedó compuesto por 16.200 filas correspondientes a 216 países, dentro del período comprendido entre 1950 y 2024. Las eliminaciones realizadas quedaron documentadas en el archivo reportes/registro_limpieza.csv.

Qué se hizo con los valores fuera de rango

Un valor extremo puede ser una falla de medición o un dato real poco común, y la decisión cambia según el caso. Aquí la causa es conocida: territorios como Sint Maarten tienen una población de pocos miles de personas, de modo que cualquier emisión industrial produce cifras per cápita enormes. Corregirlos sería inventar un dato y eliminarlos haría perder el total de emisiones del territorio. Por eso se conservan y se marcan con la variable atipico_per_capita, que permite excluirlos al construir el ranking per cápita.

De los 36 valores inicialmente detectados, 34 permanecieron dentro del período de análisis comprendido entre 1950 y 2024. Estos registros fueron conservados y marcados mediante la variable atipico_per_capita, permitiendo identificarlos posteriormente al realizar comparaciones y elaborar rankings de emisiones por habitante.

Tratamiento de nulos

Cada variable recibió una estrategia propia, según lo que significa su valor faltante. Ninguna se reemplazó por cero.

Variable	Nulos iniciales	Estrategia	Justificación	Nulos finales
pais	0	Sin nulos	Columna completa en el original.	0
anio	0	Sin nulos	Columna completa en el original.	0
codigo_iso	7.931	Recuperar Kosovo (XKX) y eliminar entidades que no son países	El nulo identifica agregados (World, continentes). Kosovo es un país sin código ISO oficial y se recupera con el código de uso común.	0
poblacion	9.244	Mantener nulo	Los nulos restantes corresponden a Antártida e Isla Christmas, sin población en la fuente. No hay otra fuente para recuperarla.	150
pib	35.160	Mantener nulo	Variable auxiliar con datos hasta 2022. Imputarla con media o cero inventaría producción económica.	4.743
co2_mt	21.027	Interpolar brechas internas de hasta 5 años; mantener el resto	Una brecha corta entre dos años observados se aproxima bien con una recta. Un nulo al inicio de la serie significa que no hay registro.	897

Variable	Nulos iniciales	Estrategia	Justificación	Nulos finales
co2_per_capita_t	23.902	Recalcular como co2 por población	Es una razón exacta entre dos variables ya disponibles.	980
variacion_anual_pct	24.172	Mantener nulo	El primer año de cada serie no tiene año anterior; la variación no está definida.	1.068
participacion_mundial_pct	22.848	Recalcular como co2 país sobre co2 mundial	Se usa la serie mundial del mismo archivo.	897
co2_acumulado_mt	22.848	Interpolar brechas internas de hasta 5 años; mantener el resto	Mismo criterio que co2: es una serie monótona y creciente.	897

Tabla 4. Tratamiento de nulos por variable. Los nulos iniciales corresponden al archivo original completo.

La mayor parte de la reducción de nulos viene de dos decisiones previas: acotar el período a 1950 y quitar las entidades que no son países. Sobre lo que quedó, solo se completaron 8 valores, todos de Esuatini (Eswatini) en 1962 y 1963: la interpolación de co2 y de co2 acumulado, y el recálculo de las emisiones per cápita y de la participación mundial a partir de ellos.

Los ocho valores completados se distribuyen en cuatro variables: dos correspondientes a co2_mt, dos a co2_acumulado_mt, dos a co2_per_capita_t y dos a participacion_mundial_pct. Estas modificaciones se realizaron utilizando interpolación y recálculo de variables relacionadas, manteniendo la coherencia entre los datos.

Por qué no se imputó con media, mediana o cero

Una serie de emisiones tiene tendencia: reemplazar un año faltante por el promedio de todo el período mezclaría décadas muy distintas. Por eso solo se interpola entre años vecinos y solo si la brecha no supera cinco años. Un cero tampoco es neutro, porque afirmaría que el país no emitió, cuando en realidad no hay registro.

Qué nulos permanecen y por qué

- **co2 (897):** 875 corresponden al inicio de la serie de 41 países que aparecen en los datos después de 1950, y 22 a brechas de 10 y 12 años en Isla Christmas y Santa Elena, mayores que el máximo permitido.
- **poblacion (150):** Antártida e Isla Christmas no tienen población en la fuente. En la Antártida el nulo además tiene sentido, porque no hay población permanente.
- **pib (4.743):** el PIB termina en 2022 y no cubre a todos los países. Es una variable auxiliar.
- **variacion_anual_pct (1.068):** el primer año de cada serie no tiene año anterior con el cual comparar.

Transformaciones aplicadas

Se aplicaron diez transformaciones con src/transformaciones.py, que cubren conversión de tipos y fechas, extracción de componentes temporales, cambio de unidades, clasificación por rangos y creación de variables.

Variable original	Transformación	Resultado	Tipo final
poblacion	float64 a entero con nulos (astype Int64)	poblacion	Int64
pais	texto a categoría	pais	category
codigo_iso	object a string	codigo_iso	string

Variable original	Transformación	Resultado	Tipo final
anio	pd.to_datetime(anio, format='%Y')	fecha	datetime64[us]
anio	Extraer década: anio // 10 * 10	decada	int64
anio	Clasificar por rangos (pd.cut): hasta 1996, 1997-2014, desde 2015	periodo_politica	string
co2_mt	Cambio de unidad: Mt a Gt (dividir por 1000)	co2_gt	float64
co2_mt y pib	Nueva variable: co2_mt * 1e9 / pib	co2_por_pib_kg	float64
co2_per_capita_t	Clasificar por rangos: hasta 2, 2-6, 6-12 y más de 12 t por persona	nivel_per_capita	string
co2_per_capita_t	Marcar valores mayores a 100 t por persona	atipico_per_capita	bool

Tabla 5. Transformaciones aplicadas.

Las transformaciones permitieron incorporar siete variables nuevas al conjunto de datos. La variable fecha convierte el año en un formato de fecha; decada permite agrupar los registros por décadas; periodo_politica clasifica los años según las etapas previas y posteriores a los acuerdos de Kioto y París; co2_gt convierte las emisiones de millones de toneladas a gigatoneladas; nivel_per_capita clasifica las emisiones por habitante en distintos rangos; atipico_per_capita identifica los valores superiores a 100 toneladas por persona; y co2_por_pib_kg permite analizar la intensidad de las emisiones en relación con el producto interno bruto.

```
df["fecha"] = pd.to_datetime(df["anio"].astype(str), format="%Y")
df["decada"] = (df["anio"] // 10) * 10
df["periodo_politica"] = pd.cut(df["anio"], bins=[-np.inf, 1996, 2014, np.inf],
                                labels=["pre_kioto", "kioto_a_paris", "post_paris"])
df["co2_gt"] = df["co2_mt"] / 1000
```

El período de política usa el año de adopción de cada acuerdo (Kioto 1997, París 2015) y no el de entrada en vigencia. Reparte los registros en 10.152 previos a Kioto, 3.888 entre Kioto y París y 2.160 posteriores a París. El nivel per cápita separa 7.696 registros bajos (hasta 2 t), 3.503 medios, 2.684 altos y 1.337 muy altos (más de 12 t). La intensidad co2_por_pib_kg mide los kilogramos de CO_2 por dólar de PIB y permite comparar economías de distinto tamaño.

Esta clasificación permite comparar la evolución de las emisiones entre distintos períodos históricos. Sin embargo, la coincidencia temporal entre los acuerdos ambientales y las variaciones de las emisiones no demuestra por sí sola una relación causal. Para evaluar la influencia de estas políticas será necesario incorporar información adicional sobre las medidas implementadas y sus fechas de aplicación.

Modularización del código

El código del Avance 1 estaba concentrado en carga.py. Ahora cada archivo tiene una responsabilidad y main.py solo coordina el orden. La función validar_estructura() pasó de carga.py a validaciones.py (como validar_columnas) para que carga.py se dedique únicamente a leer archivos.

Archivo	Responsabilidad	Funciones principales
src/carga.py	Lectura y carga del conjunto	cargar_datos, inspeccionar_datos
src/limpieza.py	Nulos, duplicados y normalización	normalizar_nombres, limpiar_texto, separar_paises, filtrar_periodo, eliminar_duplicados, tratar_nulos

Archivo	Responsabilidad	Funciones principales
src/transformaciones.py	Conversión y creación de variables	convertir_tipos, convertir_fecha, extraer_decada, clasificar_periodo_politica, convertir_unidades, calcular_intensidad
src/validaciones.py	Comprobación de columnas, tipos y rangos	validar_columnas, diagnosticar, contar_fuera_de_rango, validar_dataset_limpio, calcular_sha256
main.py	Ejecución ordenada del pipeline	main

La separación del código en módulos permite organizar el proyecto de manera más clara, asignando una responsabilidad específica a cada archivo. Esta estructura facilita la identificación de errores, el mantenimiento del código y la modificación de una etapa del proceso sin afectar directamente las demás. El archivo main.py coordina la ejecución de los módulos y mantiene el orden establecido para el pipeline de procesamiento.



Figura 2. Pipeline del Avance 2. Todas las etapas están implementadas y se ejecutan con python main.py.

```
    df = limpieza.normalizar_nombres(original, registro)
    df = limpieza.limpiar_texto(df, registro)
    df = limpieza.recuperar_codigos_iso(df, registro)
    mundial = limpieza.extraer_serie_mundial(df)
    df = limpieza.separar_paises(df, registro)
    df = limpieza.filtrar_periodo(df, registro)
    df = limpieza.eliminar_entidades_sin_co2(df, registro)
    df = limpieza.eliminar_duplicados(df, registro)
    ...
    df = limpieza.tratar_nulos(df, mundial, registro)
    df, tabla_trans = transformaciones.aplicar_transformaciones(df)
    errores = validaciones.validar_dataset_limpio(df)
    df.to_csv(RUTA_LIMPIO, index=False)
```

Fragmento de main.py: el orden del pipeline.

Validación y ejecución

Antes de exportar, validar_dataset_limpio() comprueba el resultado. Si algo falla, el programa informa el error y no escribe el archivo. Las verificaciones son:

- Están presentes las 17 columnas esperadas.
- Los tipos son los esperados: anio entero, fecha datetime, atipico_per_capita booleana y el resto de variables numéricas.

- No hay filas duplicadas ni pares pais y anio repetidos.
- pais y codigo_iso no tienen nulos, y codigo_iso tiene tres letras mayúsculas.
- periodo_politica contiene solo las tres categorías previstas.
- No quedan valores fuera de rango sin marcar.

Además, el programa calcula la huella SHA-256 del archivo original al comenzar y al terminar, y confirma que no cambió. El pipeline se ejecuta con python main.py desde la raíz, con rutas relativas. Se probó con pandas 3.0.2 y con pandas 2.2.3, y ambas versiones generan exactamente el mismo dataset_limpio.csv.

Comparación antes y después

Indicador	Antes	Después
Filas	50.411	16.200
Columnas	79	17
Valores nulos (todas las columnas)	2.105.184	16.470
Valores nulos (10 variables del diccionario)	167.132	9.632
Filas duplicadas	0	0
Valores fuera de rango sin marcar	36	0
Variables transformadas	0	7
Variables nuevas	0	7

Tabla 6. Comparación del conjunto antes y después del proceso.

La disminución de los valores nulos en el conjunto procesado se explica principalmente por la eliminación de columnas que no forman parte del diccionario de análisis y por la aplicación de los criterios de limpieza definidos. En las diez variables principales del diccionario, los valores nulos disminuyeron de 167.132 a 9.632. En cuanto a los valores fuera de rango, el resultado final de cero corresponde a los valores que permanecen sin identificar, ya que los 34 registros extremos que continúan dentro del período de análisis fueron conservados y marcados mediante la variable atipico_per_capita. Además, el procesamiento permitió obtener siete variables nuevas que complementan la información original.

Evidencias de ejecución

Las siguientes capturas son salida real de python main.py. El texto completo está en reportes/salida_avance2.txt.

Registro de acciones (se exporta a reportes/registro_limpieza.csv):

accion	filas_afectadas
Normalizar y renombrar columnas	10
Eliminar espacios sobrantes en texto	0
Recuperar codigo_iso de Kosovo (XKX)	174
Eliminar 35 entidades que no son países	7757
Eliminar registros anteriores a 1950	26229
Eliminar países sin datos de CO2 (Monaco, San Marino, Vatican)	225
Eliminar filas duplicadas	0
Revisar pares pais-anio repetidos	0
Interpolar brechas cortas en co2_mt	2
Interpolar brechas cortas en co2_acumulado_mt	2
Recalcular co2_per_capita_t	2
Recalcular participacion_mundial_pct	2
Mantener nulos en poblacion	150
Mantener nulos en pib	4743
Mantener nulos en variacion_anual_pct	1068

Figura 3. Registro de acciones de limpieza y tratamiento de nulos.

variable	nulos_iniciales	estrategia	nulos_finales
pais	0	Sin nulos	0
anio	0	Sin nulos	0
codigo_iso	7931	Recuperar Kosovo (XKX) y eliminar entidades q...	0
poblacion	9244	Mantener nulo	150
pib	35160	Mantener nulo	4743
co2_mt	21027	Interpolar brechas internas de hasta 5 años; ...	897
co2_per_capita_t	23902	Recalcular como co2 por población	980
variacion_anual_pct	24172	Mantener nulo	1068
participacion_mundial_pct	22848	Recalcular como co2 país sobre co2 mundial	897
co2_acumulado_mt	22848	Interpolar brechas internas de hasta 5 años; ...	897

Figura 4. Nulos iniciales, estrategia y nulos finales por variable.

Comparación antes y después:

indicador	antes	despues
Filas	50411	16200
Columnas	79	17
Valores nulos (todas las columnas)	2105184	16470
Valores nulos (10 variables del diccionario)	167132	9632
Filas duplicadas	0	0
Valores fuera de rango	36	0
Variables transformadas	0	7
Variables nuevas	0	7

Figura 5. Comparación antes y después.

```
df.info() del dataset limpio:
<class 'pandas.DataFrame'>
RangeIndex: 16200 entries, 0 to 16199
Data columns (total 17 columns):
 #   Column                   Non-Null Count  Dtype
---  ------                   --------------  -----
 0   pais                     16200 non-null  category
 1   codigo_iso               16200 non-null  string
 2   anio                     16200 non-null  int64
 3   fecha                    16200 non-null  datetime64[us]
 4   decada                   16200 non-null  int64
 5   periodo_politica         16200 non-null  string
 6   poblacion                16050 non-null  Int64
 7   pib                      11457 non-null  float64
 8   co2_mt                   15303 non-null  float64
 9   co2_gt                   15303 non-null  float64
 10  co2_per_capita_t         15220 non-null  float64
 11  nivel_per_capita         15220 non-null  string
 12  atipico_per_capita       16200 non-null  bool
 13  co2_por_pib_kg           11239 non-null  float64
 14  variacion_anual_pct      15132 non-null  float64
 15  participacion_mundial_pct  15303 non-null  float64
 16  co2_acumulado_mt         15303 non-null  float64
dtypes: Int64(1), bool(1), category(1), datetime64[us](1), float64(8), int64(2), string(3)
memory usage: 1.9 MB
```

Figura 6. df.info() del dataset limpio.

```
df[columnas].sample(5, random_state=1):
            pais  anio periodo_politica  co2_mt  co2_per_capita_t nivel_per_capita  atipico_per_capita
12131      Rwanda  2006    kioto_a_paris   0.514             0.055            bajo               False
5653      Georgia  1978        pre_kioto  12.339             2.423           medio               False
11342      Panama  1967        pre_kioto   2.150             1.548            bajo               False
9804   Montserrat  2004    kioto_a_paris   0.048            10.489            alto               False
15155      Uganda  1955        pre_kioto   0.264             0.040            bajo               False
```

Figura 7. Muestra del dataset limpio.

Diccionario del dataset limpio

Variable	Descripción	Tipo	Unidad o formato	Nulos finales
pais	Nombre del país	category	Texto (inglés)	0
codigo_iso	Código del país	string	ISO 3166-1 alfa-3 (XKX para Kosovo)	0
anio	Año de observación	int64	AAAA, 1950 a 2024	0
fecha	Fecha del 1 de enero del año	datetime64[us]	AAAA-MM-DD	0
decada	Década del año	int64	AAAA (1950, 1960, ...)	0
periodo_politica	Etapa según Kioto y París	string	pre_kioto, kioto_a_paris, post_paris	0
poblacion	Población	Int64	Personas	150
pib	Producto interno bruto	float64	Dólares internacionales de 2011	4.743
co2_mt	Emisiones anuales de CO_2	float64	Millones de toneladas	897
co2_gt	Emisiones anuales de CO_2	float64	Miles de millones de toneladas	897
co2_per_capita_t	Emisiones por habitante	float64	Toneladas por persona	980
nivel_per_capita	Nivel de emisiones por habitante	string	bajo, medio, alto, muy_alto	980
atipico_per_capita	Marca de valor sobre 100 t por persona	bool	Verdadero o falso	0

Variable	Descripción	Tipo	Unidad o formato	Nulos finales
co2_por_pib_kg	Intensidad de carbono	float64	kg de CO_2 por dólar de PIB	4.961
variacion_anual_pct	Variación anual de las emisiones	float64	Porcentaje	1.068
participacion_mundial_pct	Participación en las emisiones mundiales	float64	Porcentaje	897
co2_acumulado_mt	Emisiones acumuladas	float64	Millones de toneladas	897

Tabla 7. Diccionario de datos del dataset procesado.

Repositorio

El repositorio actualizado está en [fernandagarcia111/emisiones-co2-pipeline: Pipeline en Python y Pandas para analizar la evolución de emisiones de CO2 (Programación Avanzada, Grupo 6)]. Los commits del avance son:

- Mueve el dataset original a datos/originales
- Agrega diagnóstico inicial de calidad
- Implementa limpieza y tratamiento de valores nulos
- Incorpora transformaciones de fechas y variables
- Separa validaciones en un módulo y actualiza main.py
- Exporta dataset limpio
- Actualiza informe del avance 2

Conclusión

Durante el segundo avance del Proyecto Final Integrador se logró preparar el conjunto de datos de emisiones de CO_2 mediante un proceso de diagnóstico, limpieza, tratamiento de valores nulos, transformación y validación utilizando Python y Pandas. El archivo original contenía 50.411 registros y 79 columnas. Después de aplicar los criterios de limpieza definidos, se eliminaron 34.211 registros y se obtuvo un conjunto procesado de 16.200 filas correspondientes a 216 países, con 17 variables. Además, se verificó que no existieran filas duplicadas ni pares repetidos de país y año.

En el tratamiento de valores nulos se utilizaron estrategias diferenciadas según el significado de cada variable. Solamente se completaron ocho valores correspondientes a Esuatini durante los años 1962 y 1963, mediante interpolación y recálculo de variables relacionadas. Los demás valores faltantes se conservaron cuando no existía información suficiente para recuperarlos de manera confiable, evitando reemplazarlos injustificadamente por cero o por promedios.

También se aplicaron diez transformaciones que permitieron generar siete variables nuevas, facilitando la organización temporal, la clasificación de emisiones y la identificación de valores atípicos. Los valores extremos que correspondían a situaciones reales fueron conservados y marcados para permitir su identificación durante los análisis posteriores. A pesar de los avances, permanecen algunas limitaciones, como la presencia de valores de CO_2 iguales a cero que requieren revisión, los datos faltantes de PIB y la necesidad de establecer criterios comunes para

comparar países. Asimismo, será necesario incorporar información externa sobre los acuerdos y las políticas ambientales y sus fechas de aplicación.

En conclusión, el conjunto de datos se encuentra preparado para continuar con el análisis de la evolución de las emisiones, la elaboración de rankings y la comparación entre períodos. Sin embargo, los resultados deberán interpretarse considerando las limitaciones identificadas y sin asumir que las variaciones de emisiones se explican exclusivamente por las políticas ambientales.

Referencias

Friedlingstein, P., O'Sullivan, M., Jones, M. W., Andrew, R. M., et al. (2025). Global Carbon Budget 2025. Global Carbon Project. https://globalcarbonbudget.org/

Our World in Data. (2026). Data on CO2 and greenhouse gas emissions [Conjunto de datos]. GitHub. https://github.com/owid/co2-data

Ritchie, H., Rosado, P., & Roser, M. (2023). CO_2 and greenhouse gas emissions. Our World in Data. https://ourworldindata.org/co2-and-greenhouse-gas-emissions

McKinney, W. (2022). Python for data analysis (3.ª ed.). O'Reilly Media.

The pandas development team. (s. f.). pandas documentation. https://pandas.pydata.org/docs/

Naciones Unidas. (1998). Protocolo de Kioto de la Convención Marco de las Naciones Unidas sobre el Cambio Climático. https://unfccc.int/kyoto_protocol

Naciones Unidas. (2015). Acuerdo de París. https://unfccc.int/process-and-meetings/the-paris-agreement