PROGRAMACIÓN AVANZADA

ING. CIVIL PLAN COMUN– SEDE TEMUCO

"CO2 EN EL TIEMPO”

Nº Grupo	:	6
Integrantes	:	Benjamin Fuentes
		Fernanda García
		Martín Inostroza
Fecha	:	27/10/2026
Nota	:	

INFORME N°1

Características generales

El conjunto de datos CO_2 and Greenhouse Gas Emissions, publicado por Our World in Data, contiene información histórica sobre las emisiones de CO_2 por país y año. Está disponible en formato CSV y puede procesarse con Python y Pandas. Incluye variables como país, año, emisiones de CO_2 y población. Permite comparar las emisiones a lo largo del tiempo, pero debe complementarse con datos sobre políticas ambientales para responder la pregunta del proyecto.

1. Descripción del problema

El cambio climático es uno de los principales desafíos ambientales a nivel mundial y está relacionado, entre otros factores, con las emisiones de dióxido de carbono (CO_2) generadas por actividades humanas, como la producción de energía, el transporte y los procesos industriales. Frente a esta situación, distintos países han implementado políticas ambientales, tales como impuestos al carbono, incentivos para utilizar energías renovables y regulaciones para disminuir las emisiones contaminantes. Sin embargo, es necesario analizar los datos disponibles para conocer cómo han evolucionado las emisiones y evaluar si existen relaciones entre estas variaciones y las políticas implementadas.

Organización, proceso relacionado y necesidad detectada

El proyecto se relaciona con el proceso de seguimiento y evaluación de las emisiones de CO_2 y de las medidas ambientales adoptadas por los países. Para ello, se utilizarán datos de fuentes públicas, principalmente Our World in Data, complementados con información sobre políticas ambientales de organismos especializados. La necesidad detectada consiste en organizar y comparar esta información de manera sistemática, ya que los datos de emisiones, por sí solos, no permiten identificar qué políticas se aplicaron ni determinar su efectividad. Por esta razón, se requiere preparar los datos mediante herramientas de análisis como Python y Pandas, verificando su calidad antes de obtener conclusiones.

Pregunta principal del proyecto: ¿Las políticas ambientales han influido en la reducción de emisiones de CO_2?

Objetivo general: Analizar la evolución de las emisiones de CO_2 y su relación con las políticas ambientales implementadas en distintos países y períodos, utilizando herramientas de procesamiento y análisis de datos.

Objetivos específicos: (1) Recopilar y organizar datos históricos sobre emisiones de CO_2 y políticas ambientales a partir de fuentes confiables. (2) Utilizar Pandas para cargar, inspeccionar y preparar los datos, identificando valores faltantes, registros duplicados y posibles inconsistencias. (3) Comparar la evolución de las emisiones entre países y períodos, considerando las políticas ambientales identificadas. (4) Elaborar conclusiones basadas en los resultados obtenidos, reconociendo las limitaciones del análisis.

Usuarios potenciales y decisiones que podrían apoyarse

Los resultados podrían ser útiles para estudiantes, docentes, investigadores, organizaciones ambientales y responsables de políticas públicas. Esta información podría apoyar decisiones relacionadas con la priorización de medidas de reducción de emisiones, la identificación de períodos que requieren mayor atención y la selección de

países o políticas que convendría estudiar con mayor profundidad. El análisis permitirá identificar posibles asociaciones, sin asumir que las políticas ambientales son la única causa de las variaciones observadas.

2. Fuente de datos

Para desarrollar el proyecto se utilizará el conjunto de datos CO_2 and Greenhouse Gas Emissions, publicado por Our World in Data. Este conjunto reúne información histórica sobre emisiones de dióxido de carbono, emisiones por habitante, población y otros indicadores relacionados con la energía y los gases de efecto invernadero. Los datos provienen de distintas fuentes, entre ellas el Global Carbon Project, y son recopilados y procesados por Our World in Data. La fuente resulta adecuada porque permite observar la evolución anual de las emisiones por país o región y comparar distintos períodos. Sin embargo, para responder completamente la pregunta de investigación será necesario complementarla con datos específicos sobre las políticas ambientales implementadas y sus fechas de aplicación.

Elemento	Información del proyecto
Nombre del conjunto de datos	CO_2 and Greenhouse Gas Emissions.
Organización responsable	Our World in Data. Los datos originales proceden de distintas organizaciones y fuentes especializadas.
URL o ubicación del archivo	Repositorio: https://github.com/owid/co2-data. Archivo CSV: https://owidpublic.owid.io/data/co2/owid-co2-data.csv
Fecha de consulta	27 de octubre de 2026.
Formato	CSV, compatible con Python y Pandas.
Cantidad aproximada de registros	50.411 filas en la versión documentada el 4 de diciembre de 2025
Cantidad de variables	79 columnas
Periodo cubierto	La serie histórica de emisiones de CO_2 incluye datos desde 1750. El período disponible puede variar según la variable y la versión del archivo.
Licencia o condición de uso	Los datos y contenidos producidos por Our World in Data se publican bajo licencia Creative Commons BY. Los datos de terceros pueden tener condiciones distintas, por lo que se revisarán sus licencias y se citarán las fuentes originales.
Frecuencia de actualización	Los datos se actualizan cuando se publican nuevas versiones de las fuentes originales. Las principales series de emisiones se actualizan generalmente de forma anual.
Limitaciones detectadas	El conjunto no identifica por sí solo las políticas ambientales aplicadas por cada país. Puede contener valores faltantes, diferencias de cobertura entre países y estimaciones. Además, una asociación entre políticas y emisiones no demuestra necesariamente una relación causal.

Se seleccionó esta fuente porque proporciona información estructurada, documentada y adecuada para el procesamiento con Pandas. Su formato CSV permite cargar los datos, revisar sus dimensiones, identificar las variables, detectar valores faltantes y preparar comparaciones entre países y años.

3. Diccionario de datos

Se documentan las diez variables que se usarán en el análisis. Las otras 69 columnas del archivo corresponden sobre todo a desagregaciones por combustible (carbón, petróleo, gas), otros gases de efecto invernadero y cambio de temperatura. Se dejan fuera porque no son necesarias para el ranking, la evolución y la proyección de CO_2, y 9 de ellas tienen más de un 90 % de valores nulos. Los tipos originales son los que entrega Pandas al leer el archivo.

Variable	Descripción	Tipo original	Tipo esperado	Unidad o formato	Valores permitidos	¿Permite nulos?	Ejemplo (Chile, 2022)
country	Nombre del país o región	object	category	Texto (nombre en inglés)	Nombres OWID; incluye agregados como World	No	Chile
year	Año de observación	int64	int64	AAAA	1750 a 2024	No	2022
iso_code	Código del país	object	string	ISO 3166-1 alfa-3	3 letras mayúsculas; vacío en agregados	Sí	CHL
population	Población	float64	Int64	Personas	Enteros positivos	Sí	19.553.033
gdp	Producto interno bruto	float64	float64	Dólares internacionales de 2011	Mayor que 0	Sí	448.338.105.532
co2	Emisiones anuales de CO_2, sin cambio de uso de suelo	float64	float64	Millones de toneladas (Mt)	Mayor o igual que 0	Sí	35,744
co2_per_capita	Emisiones de CO_2 por habitante	float64	float64	Toneladas por persona	Mayor o igual que 0	Sí	4,385
co2_growth_prct	Variación anual de las emisiones	float64	float64	Porcentaje (%)	Real; puede ser negativo	Sí	2,527
share_global_co2	Participación en las emisiones mundiales del año	float64	float64	Porcentaje (%)	Entre 0 y 100	Sí	0,228
cumulative_co2	Emisiones acumuladas desde el primer año con dato	float64	float64	Millones de toneladas (Mt)	Mayor o igual que 0	Sí	3.168,522

Clasificación de las variables

- Numéricas: population, gdp, co2, co2_per_capita, co2_growth_prct, share_global_co2 y cumulative_co2.
- Categórica: country. Mezcla países con agregados (World, continentes, grupos de ingreso), por lo que habrá que separarlos.
- Fecha: year, almacenado como entero. Al ser anual no requiere conversión a datetime.
- Booleanas: ninguna.
- Identificadores: iso_code identifica a cada país. El par country y year identifica de forma única cada registro.
- Código especial: iso_code vacío indica que la fila no es un país (7.931 filas, 36 entidades).
- Valores faltantes: se representan como NaN. Un nulo significa dato no disponible y no cero.
- Posibles errores de formato: valores extremos en co2_per_capita en territorios de población muy pequeña, como Sint Maarten (Dutch part) en 1954 (782,7 t por persona).

4. Diseño del pipeline

El pipeline representa las etapas necesarias para transformar los datos originales sobre emisiones de CO_2 en información útil para responder la pregunta de investigación: ¿Las políticas ambientales han influido en la reducción de emisiones de CO_2?. El proceso se desarrollará mediante Python y las bibliotecas Pandas, NumPy y Matplotlib. Aunque durante el primer avance se priorizará la carga e inspección inicial de los datos, se diseñará el flujo completo para orientar las siguientes etapas del proyecto.



Etapa	Entrada	Proceso	Salida	Herramienta
Obtención	Fuentes públicas	Localizar y descargar los conjuntos de datos	Archivos CSV originales	Our World in Data y fuente de políticas ambientales
Almacenamiento	Archivos descargados	Guardar los archivos en la carpeta correspondiente	Archivos en data/	Sistema de archivos
Carga	Archivo CSV	Leer los datos y crear un DataFrame	DataFrame inicial	Python y Pandas
Validación	DataFrame inicial	Revisar dimensiones, columnas y tipos de datos	Diagnóstico de estructura	Pandas
Limpieza	Datos originales	Revisar nulos, duplicados, formatos y valores inconsistentes	Datos preparados	Pandas y NumPy
Transformación	Datos preparados	Seleccionar variables, unificar formatos y relacionar país y año entre fuentes	Datos integrados	Pandas
Análisis	Datos integrados	Calcular variaciones y comparar emisiones entre países y periodos	Indicadores y resultados	Pandas y NumPy

Visualización	Indicadores calculados	Elaborar gráficos de evolución y comparación	Figuras y gráficos	Matplotlib
Interpretación	Tablas y gráficos	Identificar tendencias y considerar limitaciones	Hallazgos fundamentados	Análisis del equipo
Reporte	Resultados e interpretaciones	Documentar metodología, evidencias y conclusiones	Informe final en PDF	Procesador de texto y PDF

Selección de la fuente: se utilizará Our World in Data porque proporciona datos históricos estructurados sobre emisiones de CO_2, adecuados para estudiar su evolución por país y año. Se incorporará una segunda fuente con información sobre políticas ambientales, ya que la primera no permite identificar por sí sola las medidas implementadas.

Almacenamiento de los datos: los archivos se organizarán dentro de la carpeta datos/, manteniendo separados los datos originales y los resultados procesados cuando sea necesario. Si el tamaño o las condiciones de uso impiden subir un archivo a GitHub, se incluirán en el README el enlace oficial y las instrucciones para descargarlo.

Validación de columnas: se utilizarán herramientas de Pandas como shape, columns, dtypes y head() para comprobar las dimensiones, los nombres de las variables, sus tipos y los primeros registros. También se verificará que las columnas necesarias estén disponibles.

Tratamiento de valores faltantes: se identificarán mediante isna().sum(). Según la variable y la cantidad de datos ausentes, se evaluará conservar los registros, excluirlos de cálculos específicos o aplicar otro tratamiento justificado. No se reemplazarán valores faltantes automáticamente por cero, porque eso podría alterar los resultados.

Transformaciones esperadas: se revisarán los tipos de datos, los registros duplicados y los valores inconsistentes. Posteriormente, se seleccionarán las variables relevantes y se integrarán las fuentes mediante campos compatibles, como país y año, después de comprobar que sus definiciones sean comparables.

Resultados esperados: se pretende generar tablas y gráficos que muestren la evolución de las emisiones de CO_2, las diferencias entre países y las variaciones observadas en períodos relacionados con la implementación de políticas ambientales. Los resultados permitirán identificar posibles asociaciones, sin asumir que las políticas son la única causa de los cambios registrados.

Alcance del avance

En esta primera etapa se priorizará la descarga, el almacenamiento, la carga y la validación inicial del conjunto de datos de emisiones. Las etapas de limpieza, integración de políticas ambientales, análisis, visualización e interpretación forman parte del diseño completo y se implementarán progresivamente. Sus resultados se documentarán una vez ejecutados los procesos correspondientes.

5. Cargar datos Pandas

La carga está en src/carga.py. cargar_datos() elige el lector de Pandas según la extensión del archivo (CSV, JSON o Excel), retorna un DataFrame y captura los errores más comunes de lectura: archivo inexistente, archivo vacío, error de interpretación y codificación incompatible. Si algo falla, informa el motivo y retorna None, y main.py termina sin procesar. La ruta es relativa a la raíz del proyecto, por lo que el programa se ejecuta con python main.py en cualquier equipo.

```
def cargar_datos(ruta):
    """
    Carga un conjunto de datos desde un archivo (CSV, JSON o Excel).

    Parámetros
    ----------
ruta : str
        Ruta relativa del archivo.

    Retorna
    -------
    pandas.DataFrame
        DataFrame con los datos cargados, o None si ocurre un error.
    """
    extension = os.path.splitext(ruta)[1].lower()
try:        if extension == ".csv":            datos =
pd.read_csv(ruta)        elif extension ==
".json":
            datos = pd.read_json(ruta)        elif
extension in (".xlsx", ".xlsm", ".xls"):
datos = pd.read_excel(ruta)        else:
            print(f"Error: formato '{extension}' no soportado.")
return None        return datos     except
FileNotFoundError:
        print(f"Error: no se encontró el archivo '{ruta}'.")
except pd.errors.EmptyDataError:
        print("Error: el archivo no contiene datos.")
except pd.errors.ParserError:
        print("Error: no fue posible interpretar el archivo.")
except UnicodeDecodeError:
        print("Error: la codificación del archivo no es compatible.")
return None
```

```
def validar_estructura(datos, columnas=COLUMNAS_ESPERADAS):
"""Verifica que el DataFrame contenga las columnas necesarias.

   Retorna True si están todas presentes; en caso contrario informa
cuáles faltan y retorna False.
   """
   faltantes = [c for c in columnas if c not in datos.columns]
if faltantes:
      print(f"Advertencia: faltan columnas esperadas: {faltantes}")
return False
   print("Estructura válida: están presentes todas las columnas esperadas.")
return True
```

inspeccionar_datos() imprime las dimensiones, los nombres de columnas, los tipos, los primeros cinco registros, los nulos por columna, las filas duplicadas y el resumen estadístico. El archivo principal importa estas funciones:

```
from src.carga import cargar_datos, inspeccionar_datos, validar_estructura



def main():    ruta = "datos/owid-
co2-data.csv"    datos =
cargar_datos(ruta)

   if datos is not None:       print("Carga
realizada correctamente.")
validar_estructura(datos)
inspeccionar_datos(datos)    else:
      print("El programa finalizó sin procesar los datos.")



if __name__ == "__main__":
main()
```

6. Resultados de la inspección inicial

La siguiente salida corresponde a la ejecución real de main.py desde la raíz del repositorio. Pandas abrevia las tablas largas con puntos suspensivos; aquí se muestran fragmentos y la salida completa queda guardada en reportes/salida_main.txt.

```
$ python main.py
Carga realizada correctamente.
Estructura válida: están presentes todas las columnas esperadas.

Dimensiones:
(50411, 79)

Tipos de datos:
country                 str year                int64 iso_code              str
population              float64 gdp             float64                     ...
Length: 79, dtype: object


Valores nulos por columna:
country                 0 year                  0 iso_code              7931
population              9244 gdp                35160
                    ...
Filas duplicadas:
0
```

Característica	Resultado
Filas y columnas	50.411 filas y 79 columnas
Tipos de datos	76 columnas float64, 1 int64 (year) y 2 de texto (country, iso_code)
Entidades	254 en total: 218 países con código ISO y 36 agregados sin código
Período	1750 a 2024
Valores nulos	2.105.184 en total (52,9 % de las celdas)

Variable	Nulos	% del total
country	0	0,0
year	0	0,0
iso_code	7.931	15,7
population	9.244	18,3
gdp	35.160	69,7
co2	21.027	41,7
Variable	**Nulos**	**% del total**
co2_per_capita	23.902	47,4

co2_growth_prct	24.172	47,9
share_global_co2	22.848	45,3
cumulative_co2	22.848	45,3

Las columnas de identificación (country y year) están completas y los tipos de las variables principales son los esperados. Los nulos de iso_code corresponden a las 36 entidades que no son países, de modo que no son un error y sirven para separarlas. Los de co2 se concentran en los primeros años de la serie: entre los países con datos desde 1990 faltan 122 valores de co2, un 1,6 %. En co2_per_capita, cerca del 90 % de los nulos corresponde a años anteriores a 1950.

7. Problemas detectados en los datos

Problema detectado	Variable afectada	Cantidad	Posible tratamiento
Valores nulos	co2	21.027 (41,7 %)	Acotar el período y las entidades; interpolar huecos cortos; excluir series incompletas
Valores nulos	co2_per_capita	23.902 (47,4 %)	Recalcular como co2 por población cuando existan ambos
Valores nulos	population	9.244 (18,3 %)	Excluir las entidades sin población en el análisis per cápita
Valores nulos	gdp	35.160 (69,7 %)	Usar solo como variable auxiliar; los datos terminan en 2022
Agregados mezclados con países	country, iso_code	36 entidades, 7.931 filas	Filtrar las filas sin iso_code antes de calcular rankings, para no contar dos veces
Etiquetas duplicadas con sufijo (GCP)	country	12 entidades	Excluirlas; repiten regiones ya presentes
Valores extremos	co2_per_capita	Máximo de 782,7 t por persona (Sint Maarten (Dutch part), 1954)	Fijar una población mínima para el ranking per cápita
Ceros en emisiones	co2	1.354 registros en 50 entidades	Revisar si son ceros reales o datos ausentes; verificar caso por caso
Columnas casi vacías	9 columnas	Más de 90 % de nulos en 9	No incluirlas en el análisis
Nombres poco descriptivos	Todas	79 columnas en inglés y abreviadas	Renombrar a español en la etapa de transformación
Filas duplicadas	Todas	0	Sin acción; se mantendrá la verificación en el pipeline
Fechas como texto o números como cadenas	year y numéricas	0	No aplica; los tipos son correctos

En este avance no se aplicó ninguna corrección: los problemas se identificaron y se propone cómo abordarlos en el Avance 2.

Repositorio: https://github.com/fernandagarcia111/emisiones-co2-pipeline

8. Conclusión

La fuente seleccionada permite abordar el problema, con una salvedad. Our World in Data entrega emisiones totales y per cápita para 218 países entre 1750 y 2024, lo que alcanza para construir el ranking, la evolución temporal y una proyección. Lo que no entrega son las políticas ambientales, de modo que la pregunta orientadora solo podrá responderse comparando las curvas con un registro de hitos que el equipo debe armar aparte.

El dataset tiene 50.411 registros y 79 columnas, de las cuales se usarán diez. La carga con Pandas funciona sin errores y no hay filas duplicadas ni fechas guardadas como texto. Los problemas están en otro lado: casi la mitad de los valores de emisiones per cápita faltan (47,4 %), el archivo mezcla países con agregados como World o los grupos de ingreso, y los territorios pequeños generan valores extremos, como las 782,7 toneladas por persona de Sint Maarten (Dutch part) en 1954.

En la siguiente etapa se filtrarán las entidades sin código ISO, se acotará el período de análisis, se decidirá cómo tratar los nulos y se renombrarán las columnas al español, en src/limpieza.py y src/transformacion.py. También se definirá el grupo de países a comparar y se documentará el registro de políticas.

Respuestas metacognitivas

1. ¿Qué criterio utilizaron para seleccionar el problema?

El proyecto nos fue asignado en la distribución de grupos. Antes de aceptarlo comprobamos que se pudiera responder con datos abiertos y que existiera una serie larga y comparable entre países.

2. ¿Por qué la fuente elegida es adecuada?

Reúne emisiones totales y per cápita de más de doscientos países, con cobertura anual hasta 2024, licencia abierta y un diccionario oficial. Además, el origen de los datos (Global Carbon Project) se puede verificar.

3. ¿Qué variable podría generar mayores dificultades durante la limpieza?co2_per_capita, por sus 47,4 % de nulos y sus valores extremos en territorios pequeños. El PIB también preocupa, con 69,7 % de nulos, aunque no es central para el análisis.

4. ¿Qué supuestos están realizando sobre los datos?

Que las emisiones son comparables entre países y años, que un nulo significa dato no disponible y no cero, y que las cifras miden emisiones territoriales y no el consumo. Los ceros de co2 los trataremos como dudosos hasta revisarlos.

5. ¿Qué decisión del pipeline fue más difícil?

Cuando separar los países de los agregados. Optamos por cargar el archivo completo y hacer la separación en la etapa de limpieza, para conservar el dato original y poder explicar cada filtro.

6. ¿Qué aprendieron al realizar la primera carga con Pandas?

Que con 79 columnas la consola abrevia los resultados con puntos suspensivos y hay que revisar la inspección por partes. También que describe(include="all") mezcla estadísticas numéricas y de texto en una sola tabla muy ancha.

7. ¿Qué error apareció durante la implementación?

El ejemplo de main.py del enunciado traía la condición del bloque principal sin los guiones bajos, así que el programa no ejecutaba nada y terminaba sin mostrar resultados.

8. ¿Cómo resolvieron ese error?

Escribimos la condición como if __name__ == "__main__" y ejecutamos desde la raíz del proyecto, con ruta relativa a datos/.

9. ¿Cómo distribuyeron las tareas dentro del equipo?

La distribución de tareas se realizó de manera colaborativa. Todos los integrantes participaron activamente en el desarrollo del trabajo, contribuyendo tanto en la redacción del informe como en la elaboración del diccionario de datos, el desarrollo y revisión del código, y la creación y gestión del repositorio en GitHub. Además, se realizaron revisiones conjuntas para asegurar la calidad y coherencia del proyecto final.

10. ¿Qué evidencia demuestra que el proyecto puede continuar? main.py se ejecuta sin errores, carga 50.411 registros, valida la estructura y entrega un diagnóstico completo. Los problemas están identificados y cada uno tiene un tratamiento propuesto.

Referencias

Friedlingstein, P., O'Sullivan, M., Jones, M. W., Andrew, R. M., et al. (2025). Global Carbon Budget 2025. Global Carbon Project. https://globalcarbonbudget.org/

Our World in Data. (2026). Data on CO2 and greenhouse gas emissions [Conjunto de datos]. GitHub. https://github.com/owid/co2-data

Ritchie, H., Rosado, P., & Roser, M. (2023). CO_2 and greenhouse gas emissions. Our World in Data. https://ourworldindata.org/co2-and-greenhouse-gas-emissions

McKinney, W. (2022). Python for data analysis (3.ª ed.). O'Reilly Media.

The pandas development team. (s. f.). pandas documentation. https://pandas.pydata.org/docs/

Naciones Unidas. (1998). Protocolo de Kioto de la Convención Marco de las Naciones Unidas sobre el Cambio Climático. https://unfccc.int/kyoto_protocol

Naciones Unidas. (2015). Acuerdo de París. https://unfccc.int/process-and-meetings/the-paris-agreement